

# 6 贝叶斯学习 (Bayesian learning)

代启国

大连民族大学  
计算机科学与技术系

2018 年 12 月 14 日

# 贝叶斯 (Bayes) 其人



贝叶斯 (Thomas Bayes, 1701—1761) 英国牧师、数学家。

# 贝叶斯 (Bayes) 其人



贝叶斯 (Thomas Bayes, 1701—1761) 英国牧师、数学家。

- 贝叶斯在数学方面主要研究概率论。为了证明上帝的存在，他发明了概率统计学原理，遗憾的是，他的这一美好愿望至死也未能实现。

# 贝叶斯 (Bayes) 其人



贝叶斯 (Thomas Bayes, 1701—1761) 英国牧师、数学家。

- 贝叶斯在数学方面主要研究概率论。为了证明上帝的存在，他发明了概率统计学原理，遗憾的是，他的这一美好愿望至死也未能实现。
- 他创立了贝叶斯统计理论，对于统计决策函数、统计推断、统计的估算等做出了贡献。1763 年发表了这方面的论著，对于现代概率论和数理统计都有很重要的作用。

# 贝叶斯 (Bayes) 其人



贝叶斯 (Thomas Bayes, 1701—1761) 英国牧师、数学家。

- 贝叶斯在数学方面主要研究概率论。为了证明上帝的存在，他发明了概率统计学原理，遗憾的是，他的这一美好愿望至死也未能实现。
- 他创立了贝叶斯统计理论，对于统计决策函数、统计推断、统计的估算等做出了贡献。1763 年发表了这方面的论著，对于现代概率论和数理统计都有很重要的作用。
- 贝叶斯思想和方法对概率统计的发展产生了深远的影响。今天，贝叶斯思想和方法在许多领域都获得了广泛的应用。

# 贝叶斯公式

- 先验概率:  $P(A)$ , 事件  $A$  发生的概率

# 贝叶斯公式

- 先验概率:  $P(A)$ , 事件  $A$  发生的概率
- 后验概率 (条件概率):  $P(A|B)$ , 事件  $B$  发生条件下事件  $A$  发生的概率

# 贝叶斯公式

- 先验概率:  $P(A)$ , 事件  $A$  发生的概率
- 后验概率 (条件概率):  $P(A|B)$ , 事件  $B$  发生条件下事件  $A$  发生的概率
- 联合概率:  $P(A, B)$  事件  $A$  和  $B$  同时发生的概率

$$P(A, B) = P(A|B) \cdot P(B)$$

$$P(A, B) = P(B|A) \cdot P(A)$$



# 贝叶斯公式

- 先验概率:  $P(A)$ , 事件  $A$  发生的概率
- 后验概率 (条件概率):  $P(A|B)$ , 事件  $B$  发生条件下事件  $A$  发生的概率
- 联合概率:  $P(A, B)$  事件  $A$  和  $B$  同时发生的概率

$$P(A, B) = P(A|B) \cdot P(B)$$

$$P(A, B) = P(B|A) \cdot P(A)$$

## 贝叶斯公式

$$P(A|B) = \frac{P(A, B)}{P(B)} = \frac{P(A)P(B|A)}{P(B)}$$

# 贝叶斯学习基本思想

假设一个分类任务有  $N$  种类别, 即  $y = \{c_1, c_2, \dots, c_N\}$

在现实分类任务中, 给定一个样本  $\mathbf{x}$ , 分类任务的本质就是计算  $P(c|\mathbf{x})$

# 贝叶斯学习基本思想

假设一个分类任务有  $N$  种类别, 即  $y = \{c_1, c_2, \dots, c_N\}$

在现实分类任务中, 给定一个样本  $\mathbf{x}$ , 分类任务的本质就是计算  $P(c|\mathbf{x})$

- 机器学习: 在有限的训练样本集上尽可能准确地估计后验概率  $P(c|\mathbf{x})$

# 贝叶斯学习基本思想

假设一个分类任务有  $N$  种类别, 即  $y = \{c_1, c_2, \dots, c_N\}$

在现实分类任务中, 给定一个样本  $\mathbf{x}$ , 分类任务的本质就是计算  $P(c|\mathbf{x})$

- 机器学习: 在有限的训练样本集上尽可能准确地估计后验概率  $P(c|\mathbf{x})$
- 判别式模型 (discriminative models): 通过建模后验概率  $p(c|x)$  分布模型来预测  $c$ 
  - 决策树、BP 神经网络等
- 生成式模型 (generative models): 先对联合概率  $p(c, x)$  分布模型建模, 然后通过后验概率来预测  $c$

# 贝叶斯学习基本思想

假设一个分类任务有  $N$  种类别, 即  $y = \{c_1, c_2, \dots, c_N\}$

在现实分类任务中, 给定一个样本  $\mathbf{x}$ , 分类任务的本质就是计算  $P(c|\mathbf{x})$

- 机器学习: 在有限的训练样本集上尽可能准确地估计后验概率  $P(c|\mathbf{x})$
- 判别式模型 (discriminative models): 通过建模后验概率  $p(c|x)$  分布模型来预测  $c$ 
  - 决策树、BP 神经网络等
- 生成式模型 (generative models): 先对联合概率  $p(c, x)$  分布模型建模, 然后在通过后验概率来预测  $c$
- 生成式模型:

$$P(c|x) = \frac{P(x, c)}{P(x)}$$

- 根据贝叶斯定理:

$$P(c|x) = \frac{P(c)P(x|c)}{P(x)}$$

$$P(c|\mathbf{x}) = \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})}$$

- 类先验 (prior) 概率:  $P(c)$
- 类条件概率:  $P(\mathbf{x}|c)$ , 样本集  $\mathbf{x}$  相对于类标记  $c$  的 (class-conditional probability) (亦称 “似然”)
- $P(\mathbf{x})$ : 归一化证据因子, 与类标记  $c$  无关

$$P(c|\mathbf{x}) \propto P(c)P(\mathbf{x}|c)$$

$$P(c|\mathbf{x}) \propto P(c)P(\mathbf{x}|c)$$

- $P(c)$ : 表达了样本空间中各类样本所占的比例, 根据大数定律, 当训练集包含充足的独立同分布样本时,  $P(c)$  可通过各类样本出现的频率来过估计。

# 贝叶斯学习基本思想

$$P(c|\mathbf{x}) \propto P(c)P(\mathbf{x}|c)$$

- $P(c)$ : 表达了样本空间中各类样本所占的比例, 根据大数定律, 当训练集包含充足的独立同分布样本时,  $P(c)$  可通过各类样本出现的频率来过估计。
- $P(\mathbf{x}|c)$ : 由于设计  $\mathbf{x}$  所有属性的联合概率, 假设样本的  $d$  个属性都是二值的, 则会有  $2^d$  个可能的取值, 通常远远高于训练样本数》》》无法通过频率来进行有效估计



$$P(c|\mathbf{x}) \propto P(c)P(\mathbf{x}|c)$$

- $P(c)$ : 表达了样本空间中各类样本所占的比例, 根据大数定律, 当训练集包含充足的独立同分布样本时,  $P(c)$  可通过各类样本出现的频率来过估计。
- $P(\mathbf{x}|c)$ : 由于设计  $\mathbf{x}$  所有属性的联合概率, 假设样本的  $d$  个属性都是二值的, 则会有  $2^d$  个可能的取值, 通常远远高于训练样本数》》》无法通过频率来进行有效估计

## 贝叶斯学习的关键

如何有效地估计类条件概率???

# 朴素贝叶斯分类 (Naive Bayesian classification)

- 贝叶斯学习的关键: 如何有效地估计类条件概率???
- 类条件概率: 在所有属性上的联合概率

$$P(\mathbf{x}|c) = P(x_1, x_2, \dots, x_d|c)$$

# 朴素贝叶斯分类 (Naive Bayesian classification)

- 贝叶斯学习的关键: 如何有效地估计类条件概率???
- 类条件概率: 在所有属性上的联合概率

$$P(\mathbf{x}|c) = P(x_1, x_2, \dots, x_d|c)$$

- 朴素贝叶斯分类器: 条件独立性假设 (conditional independence assumption), 在类别已知条件下, 所有属性均相互独立, 每个属性独立地对分类结果发生影响

# 朴素贝叶斯分类 (Naive Bayesian classification)

- 贝叶斯学习的关键: 如何有效地估计类条件概率???
- 类条件概率: 在所有属性上的联合概率

$$P(\mathbf{x}|c) = P(x_1, x_2, \dots, x_d|c)$$

- 朴素贝叶斯分类器: 条件独立性假设 (conditional independence assumption), 在类别已知条件下, 所有属性均相互独立, 每个属性独立地对分类结果发生影响

●

$$P(\mathbf{x}|c) = \prod_{i=1}^d P(x_i|c)$$

# 朴素贝叶斯分类 (Naive Bayesian classification)

- 贝叶斯学习的关键: 如何有效地估计类条件概率???
- 类条件概率: 在所有属性上的联合概率

$$P(\mathbf{x}|c) = P(x_1, x_2, \dots, x_d|c)$$

- 朴素贝叶斯分类器: 条件独立性假设 (conditional independence assumption), 在类别已知条件下, 所有属性均相互独立, 每个属性独立地对分类结果发生影响

$$P(\mathbf{x}|c) = \prod_{i=1}^d P(x_i|c)$$

$$P(c|\mathbf{x}) = \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i|c)$$

# 朴素贝叶斯分类 (Naive Bayesian classification)

## 朴素贝叶斯判定准则:

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in y} P(c) \prod_{i=1}^d P(x_i|c)$$

令  $D_c$  表示训练集  $D$  中第  $c$  类样本的集合, 在假设有充足的独立同分布样本的条件下, 我们可以计算第  $c$  类别的先验概率

$$P(c) = \frac{|D_c|}{|D|}$$

对于样本的属性是离散值, 令  $D_{c,x_i}$  表示  $D_c$  中第  $i$  个属性上取值为  $x_i$  的样本组成的集合, 则

$$P(x_i|c) = \frac{|D_{c,x_i}|}{|D_c|}$$

# 朴素贝叶斯分类 (Naive Bayesian classification)

朴素贝叶斯判定准则:

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in y} P(c) \prod_{i=1}^d P(x_i|c)$$

对于样本的属性是连续值, 假定

$$p(x_i|c) \sim N(\mu_{c,i}, \sigma_{c,i}^2)$$

其中,  $N(\mu_{c,i}, \sigma_{c,i}^2)$  表示第  $c$  类样本第  $i$  个属性上取值的均值和方差

$$p(x_i|c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

# 朴素贝叶斯分类 (Naive Bayesian classification)

## 拉普拉斯平滑 (修正)

- 对离散属性计算概率时, 经常容易出现概率值为 0 的情况
- 导致溢出等问题
- 为了避免这一问题, 通常要采用平滑处理 (拉普拉斯修正)

$$P(c) = \frac{|D_c| + 1}{|D| + d}$$

$$P(x_i|c) = \frac{|D_{c,x_i}| + 1}{|D_c| + d}$$




# 朴素贝叶斯分类 (Naive Bayesian classification)

## 算法

- 1 输入: 样本  $\mathbf{x}$  和训练集  $D$
- 2 计算:  $y = \{c_1, c_2, \dots, c_N\}$  中每一个类别  $c_n$  的先验概率  $P(c_n)$ , 及其在不同样本属性上的类条件概率  $P(x_i|c_n)$
- 3 输出:

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in y} P(c) \prod_{i=1}^d P(x_i|c)$$

## 朴素贝叶斯分类 (Naive Bayesian classification)

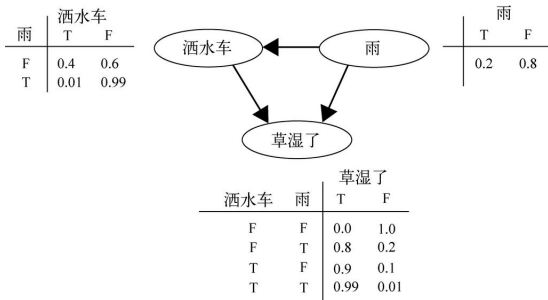


## 朴素贝叶斯中属性与类别之间的依赖关系

# 贝叶斯网 (Bayesian network)

## 贝叶斯网：也称信念网

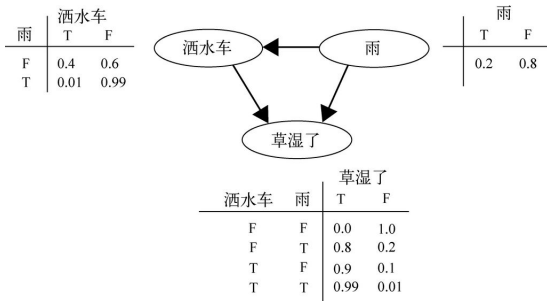
- 借助有向无环图 (Directed Acyclic Graph, DAG) 刻画属性间依赖关系
- 采用条件概率表 (Conditional Probability Table, CPT) 描述属性间的联合概率分布



# 贝叶斯网 (Bayesian network)

## 贝叶斯网

- 贝叶斯网络  $B$  由网络结构  $G$  和参数  $\theta$  两部分构成, 即  $B = (G, \theta)$
- $G$  中每个结点对应于一个属性, 结点连接表示依赖关系
- 参数  $\theta$  描述了这种依赖关系的强度




# 贝叶斯网 (Bayesian network)

## 贝叶斯网

贝叶斯网络将各属性（变量）的联合分布概率定义为：

$$P_B(x_1, x_2, \dots, x_d) = \prod_{i=1}^d P_B(x_i | \pi_i)$$




$$P(x_1, x_2, x_3, x_4, x_5) = P(x_1) P(x_2) P(x_3 | x_1) P(x_4 | x_1, x_2) P(x_5 | x_2)$$

# 贝叶斯网 (Bayesian network)

贝叶斯网络的**学习**分为两个方面

- 网络结构学习 (G) (MDL 算法等)
- 参数学习 ( $\theta$ ) (BIC 评分等)

雨	洒水车	
	T	F
F	0.4	0.6
T	0.01	0.99



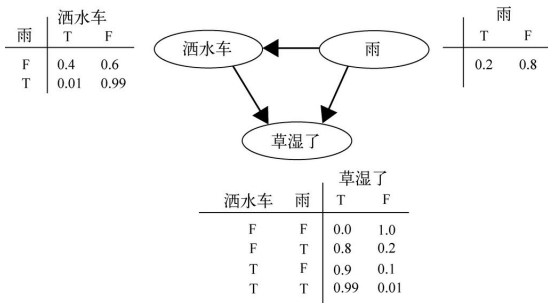
雨	T	F
	0.2	0.8

		草湿了	
洒水车	雨	T	F
F	F	0.0	1.0
F	T	0.8	0.2
T	F	0.9	0.1
T	T	0.99	0.01

# 贝叶斯网 (Bayesian network)

## 贝叶斯网络的推理

- 训练好的贝叶斯网可以用来回答问题 (推断)
- 通过已知 (观测) 的属性变量值 (证据), 推测其他未知属性变量的值
- 常用方法有吉布斯采样算法等



- 贝叶斯学习以贝叶斯理论（公式）为基础
- 通过一定的假设来构建依赖关系和强度的模型
- 朴素贝叶斯（NB）假设属性之间相互独立
- 贝叶斯网络（BN）假设属性之间是条件独立的（部分依赖）